

Машинное обучение

Лекция 4

Метрики качества классификации

Михаил Гуцин

mhushchyn@hse.ru

НИУ ВШЭ, 2022



НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ
УНИВЕРСИТЕТ

На прошлой лекции

- ▶ Модель логистической регрессии:

$$\hat{y} = \sigma(Xw)$$

- ▶ Функция потерь log-loss:

$$L = -\frac{1}{n} \sum_{i=1}^n (y_i \log(\hat{y}_i) + (1 - y_i) \log(1 - \hat{y}_i))$$

- ▶ Мы хотим минимизировать L :

$$L \rightarrow \min_w$$

- ▶ Градиентный спуск:

$$w^{(k+1)} = w^{(k)} - \eta \nabla L(w^{(k)})$$

План

- ▶ Матрица ошибок (Confusion matrix)
- ▶ Доля правильных ответов (Accuracy)
- ▶ Точность (Precision)
- ▶ Полнота (Recall)
- ▶ F_1 -мера
- ▶ ROC кривая
- ▶ Precision-Recall кривая


Матрица ошибок



Задача

Рассмотрим задачу бинарной классификации для некоторого набора данных.

Цель – **оценить качество классификатора**, определить как хорошо он разделяет объекты разных классов.



Матрица ошибок (confusion matrix)

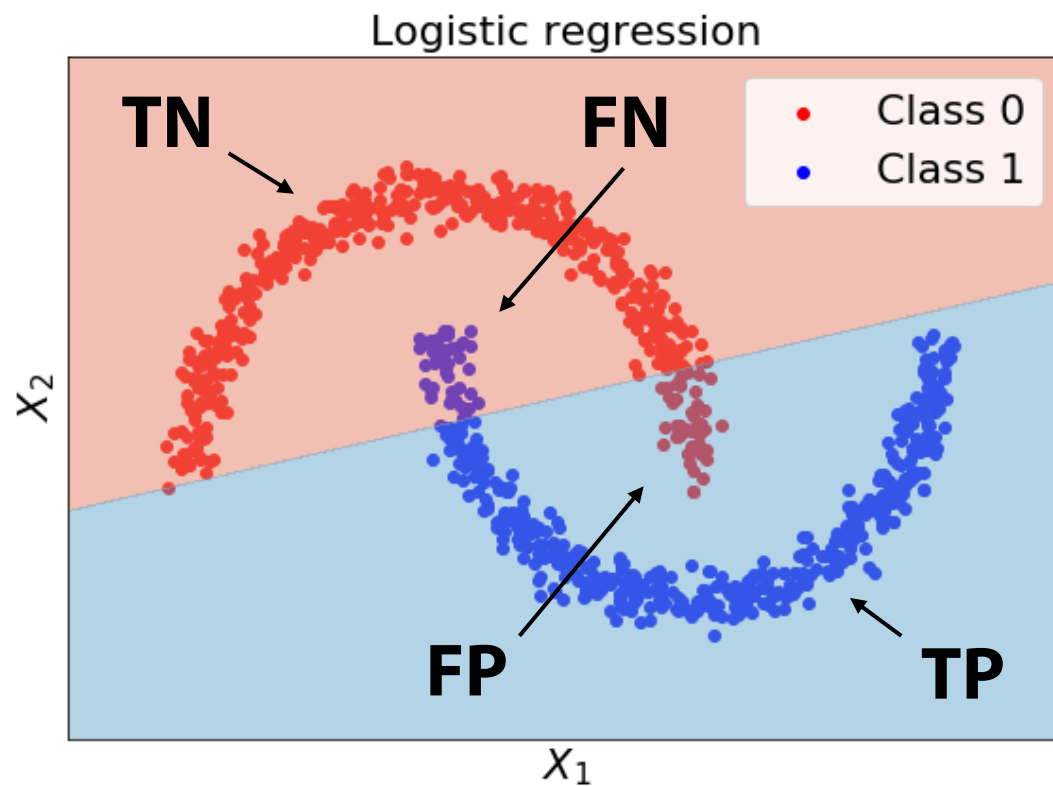
- ▶ **TP** (True Positive) – правильно предсказанные **1**
- ▶ **FP** (False Positive) – предсказанные как **1**, но правильно **0** (ошибка 1го рода)
- ▶ **TN** (True Negative) – правильно предсказанные **0**
- ▶ **FN** (False Negative) – предсказанные как **0**, но правильно **1** (ошибка 2го рода)

		PREDICTIVE VALUES	
		POSITIVE (1)	NEGATIVE (0)
ACTUAL VALUES	POSITIVE (1)	TP	FN
	NEGATIVE (0)	FP	TN



Матрица ошибок (confusion matrix)

- ▶ **TP** (True Positive) – правильно предсказанные **1**
- ▶ **FP** (False Positive) – предсказанные как **1**, но правильно **0** (ошибка 1го рода)
- ▶ **TN** (True Negative) – правильно предсказанные **0**
- ▶ **FN** (False Negative) – предсказанные как **0**, но правильно **1** (ошибка 2го рода)



Матрица ошибок (confusion matrix)

- ▶ Все **1** (*Pos*):

$$Pos = TP + FN$$

- ▶ Все **0** (*Neg*):


$$Neg = TN + FP$$

- ▶ Все прогнозы **1** (*PosPred*):

$$PosPred = TP + FP$$

- ▶ Все прогнозы **0** (*NegPred*):

$$NegPred = TN + FN$$



Метрики



Доля правильных ответов (accuracy)

- ▶ Accuracy:

$$\text{Accuracy} = \frac{TP + TN}{TP + FN + TN + FP} = \frac{TP + TN}{Pos + Neg}$$

- ▶ Error rate:

$$\text{Error rate} = 1 - \text{Accuracy}$$

- ▶ Измеряет долю верных прогнозов во всех классах

Точность (precision)

- ▶ Precision:

$$\text{Precision} = \frac{TP}{TP + FP} = \frac{TP}{PosPred}$$

- ▶ Показывает какая доля прогнозов **1** правильная

Пример: предсказали 100 объектов класса 1, но только 90 прогнозов верны.
Тогда точность = 0.9.

Полнота (recall)

- ▶ Recall:

$$\text{Recall} = \frac{TP}{TP + FN} = \frac{TP}{Pos}$$

- ▶ Показывает какую долю настоящих **1** классификатор предсказал правильно.

Пример: в данных 50 объектов класса 1, классификатор правильно предсказал 40 этих объектов. Тогда полнота = 0.8.

F-мера

- ▶ F_1 -score:


$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

- ▶ Показывает среднее геометрическое точности и полноты

Пример

Metric	Value
Accuracy	0.89
Precision	0.89
Recall	0.89
F_1	0.89

- ▶ В этом простом симметричном примере все метрики равны
- ▶ Далее увидим другие примеры



ROC кривая

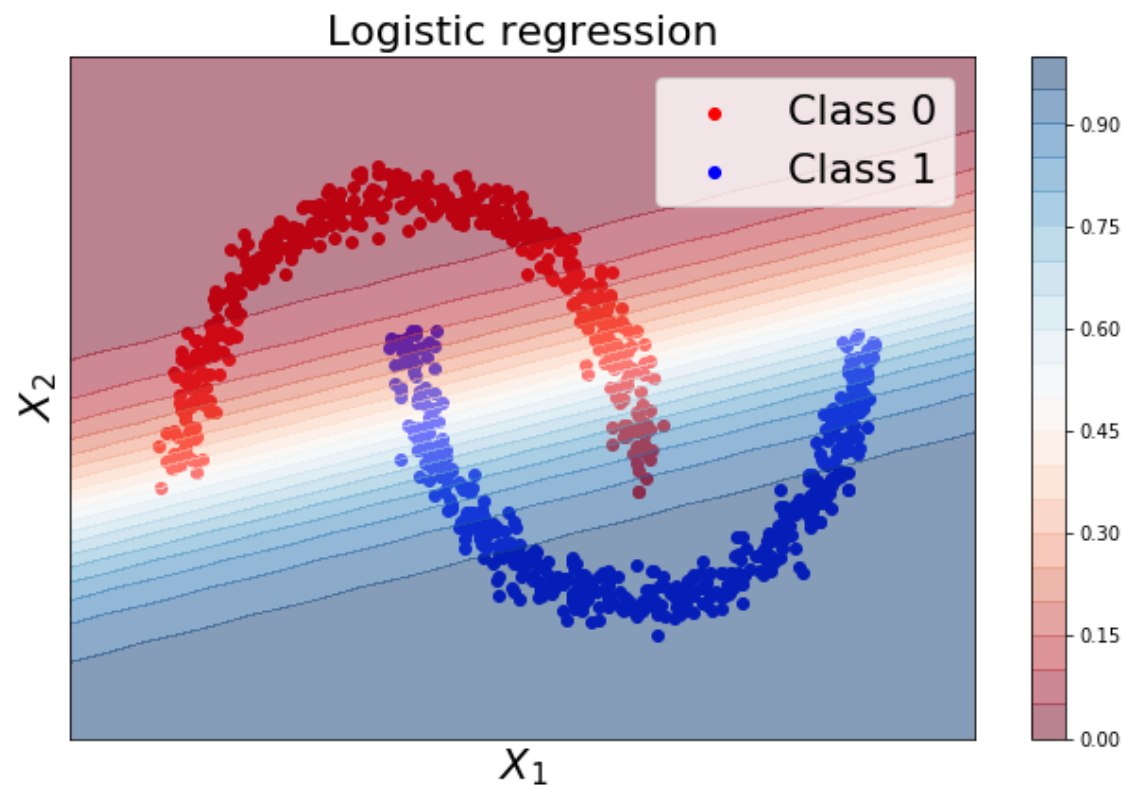



Метка класса vs вероятность класса

Прогноз **1** если $p \geq 0.5$

Прогноз **0** если $p < 0.5$

Вероятность класса **1** p :



ROC кривая

- ▶ ROC (Receiver operating characteristic) кривая – зависимость $TPR(\mu)$ от $FPR(\mu)$ для разных пороговых значений μ вероятности p


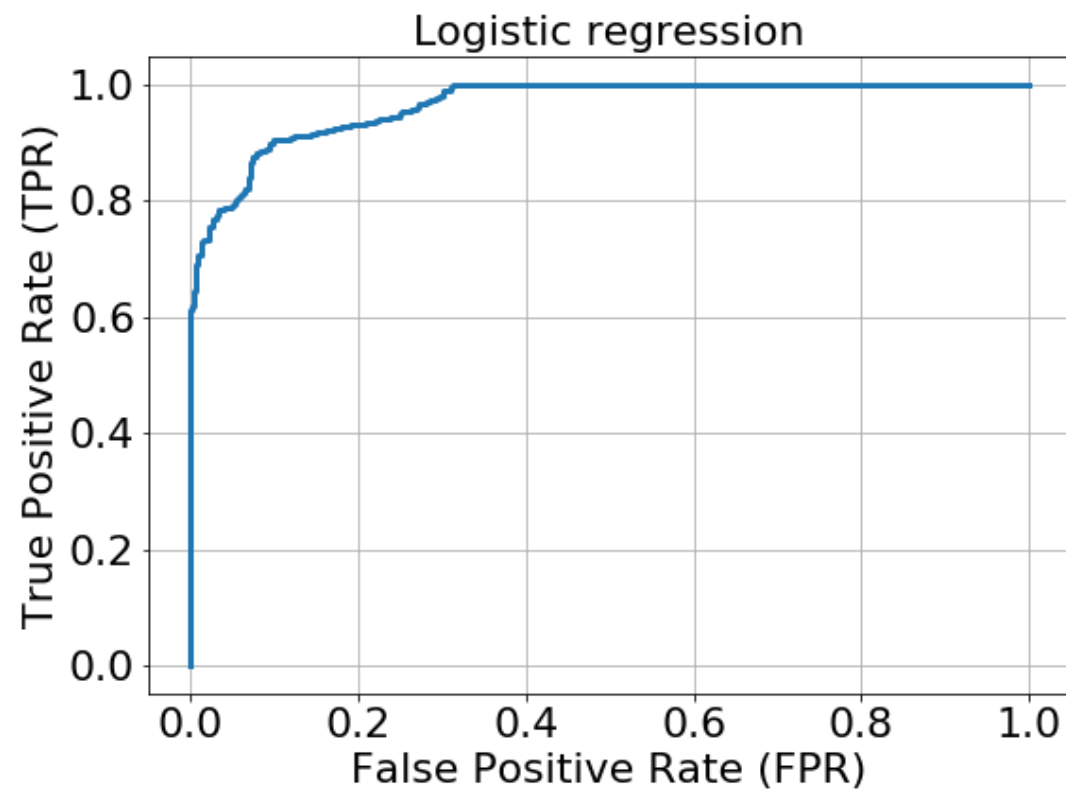
- ▶ $TPR(\mu)$ (True Positive Rate):

$$TPR(\mu) = \frac{1}{Pos} \sum_{i \in Pos} I[p_i \geq \mu] = \frac{TP(\mu)}{Pos}$$

- ▶ $FPR(\mu)$ (False Positive Rate):


$$FPR(\mu) = \frac{1}{Neg} \sum_{i \in Neg} I[p_i \geq \mu] = \frac{FP(\mu)}{Neg}$$

ROC кривая



ROC AUC

- ▶ Можно сравнивать классификаторы с помощью площади под ROC кривой (ROC AUC)
- ▶ $\text{ROC AUC} \in [0, 1]$
- ▶ $\text{ROC AUC} = 0.5$ – случайные прогнозы
- ▶ $\text{ROC AUC} = 1$ – идеальный классификатор
- ▶ $\text{ROC AUC} = 0$ – тоже идеальный классификатор, то с противоположными ответами 😊



Img: <https://glassboxmedicine.com/2019/02/23/measuring-performance-auc-auroc/>

Индекс Джини


- ▶ Gini:

$$Gini = 2 (ROC\ AUC) - 1$$

- ▶ Измеряется в диапазоне от 0 до 1

Precision-Recall кривая


- ▶ По аналогии с ROC кривой, можно построить Precision-Recall (PR) кривую
- ▶ PR – зависимость **Precision(μ)** от **Recall(μ)** для разных пороговых значений μ вероятности p



Демонстрация

Metric	1:1	1:10	10:1
Accuracy	0.89		
Precision	0.89		
Recall	0.89		
F_1	0.89		
ROC AUC	0.97		


- Обучили модель на сбалансированной выборке
- **Фиксируем модель** и будем менять баланс классов



Демонстрация

Metric	1:1	1:10	10:1
Accuracy	0.89	0.89	
Precision	0.89	0.99	
Recall	0.89	0.89	
F_1	0.89	0.94	
ROC AUC	0.97	0.97	


- Значения некоторых метрик
меняются при смене баланса классов



Демонстрация

Metric	1:1	1:10	10:1
Accuracy	0.89	0.89	0.89
Precision	0.89	0.99	0.47
Recall	0.89	0.89	0.89
F_1	0.89	0.94	0.61
ROC AUC	0.97	0.97	0.97

- **Recall** и **ROC AUC** устойчивы к дисбалансу классов
- Для **Accuracy** это не выполняется в общем случае



Заключение



Резюме

- ▶ Матрица ошибок (Confusion matrix)
- ▶ Доля правильных ответов (Accuracy)
- ▶ Точность (Precision)
- ▶ Полнота (Recall)
- ▶ F_1 -мера
- ▶ ROC кривая
- ▶ Precision-Recall кривая

Вопросы

- ▶ Что такое точность, полнота и F-мера?
- ▶ Что такое AUC-ROC? Опишите алгоритм построения ROC-кривой.